Отчет по 2 дз “ASR Decoding”

Task 1. Жадное декодирование (Greedy)

Результаты:

Датасет	**WER**	**CER**
LibriSpeech test-other	11.22%	3.81%
Earnings22	54.97%	25.58%

На in-domain данных результат близок к референсному значению 10.4% WER. Разница в 0.8% может объясняться особенностями предобработки аудио или различиями в тестовой выборке. На out-of-domain данных качество резко падает — WER возрастает в 5 раз. Это ожидаемо, так как акустическая модель обучалась исключительно на аудиокнигах и не знакома с финансовой терминологией и стилем речи.

Task 2. Beam search без языковой модели

Результаты экспериментов:

Beam width	**WER**	**CER**	**Время выполнения**
1	11.22%	3.81%	46 сек
3	11.22%	3.81%	50 сек
10	11.22%	3.81%	69 сек
50	11.22%	3.81%	216 сек

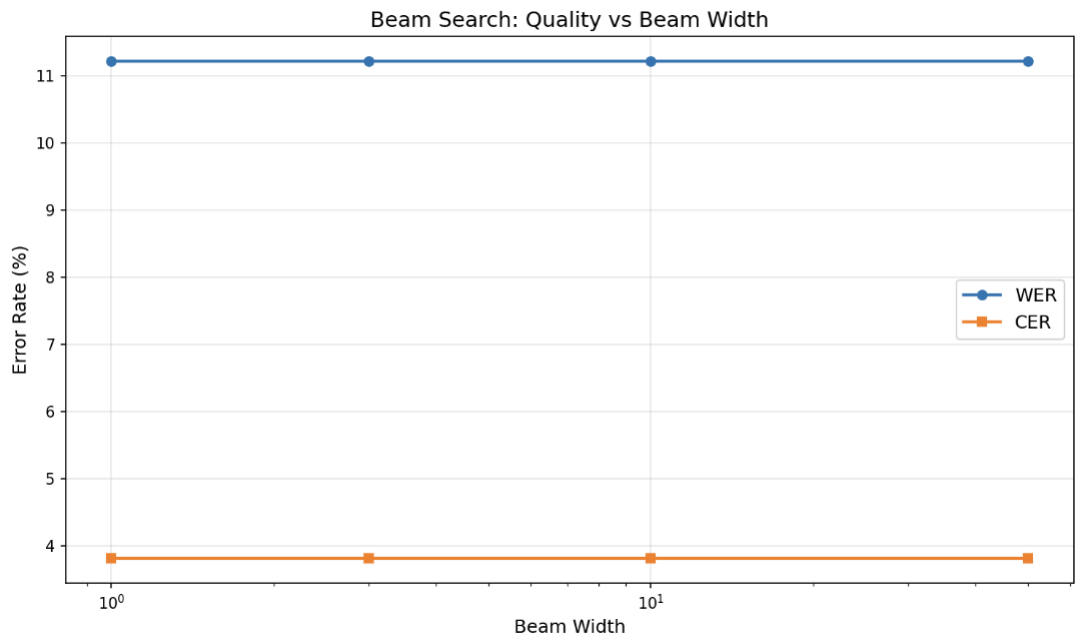

График 1. Зависимость качества от ширины луча

При увеличении ширины луча от 1 до 50 качество не изменилось. Полагаю, это объясняется тем, что акустическая модель уже хорошо обучена на in-domain данных и уверенно выбирает правильный путь — расширение луча не добавляет новых полезных гипотез. При этом время выполнения растет линейно: beam_width=50 требует в 4.7 раза больше времени, чем greedy.

Task 3. Температурное масштабирование

Температура применяется к логитам перед softmax. Влияет на уверенность модели: при T<1 распределение становится более острым, при T>1 - более плоским.

Температура	WER	CER
0.5	11.22%	3.81%
0.8	11.22%	3.81%
1.0	11.22%	3.81%
1.2	11.22%	3.81%
1.5	11.22%	3.81%

2.0	11.22%	3.81%

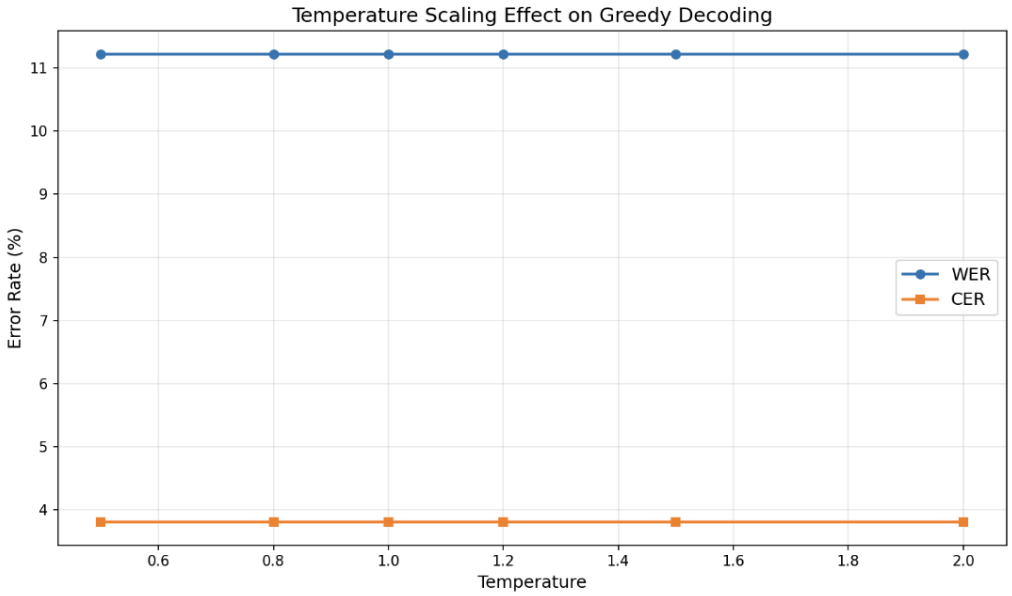

График 2. Влияние температуры на greedy decoding

На in-domain данных температура не влияет на результат. Это происходит потому, что argmax не чувствителен к температуре, пока вероятностное распределение остается унимодальным. Модель настолько уверена в своих предсказаниях на знакомом домене, что изменение температуры не меняет порядок вероятностей.

Значит, на хорошо откалиброванной модели температура не влияет на greedy decoding. Однако на out-of-domain данных эффект должен быть заметен - посмотрим ниже в таске 7b.

Task 4. Shallow fusion с 3-gram LM (мелкое слияние)

Shallow fusion добавляет LM-оценку непосредственно в процесс расширения луча.

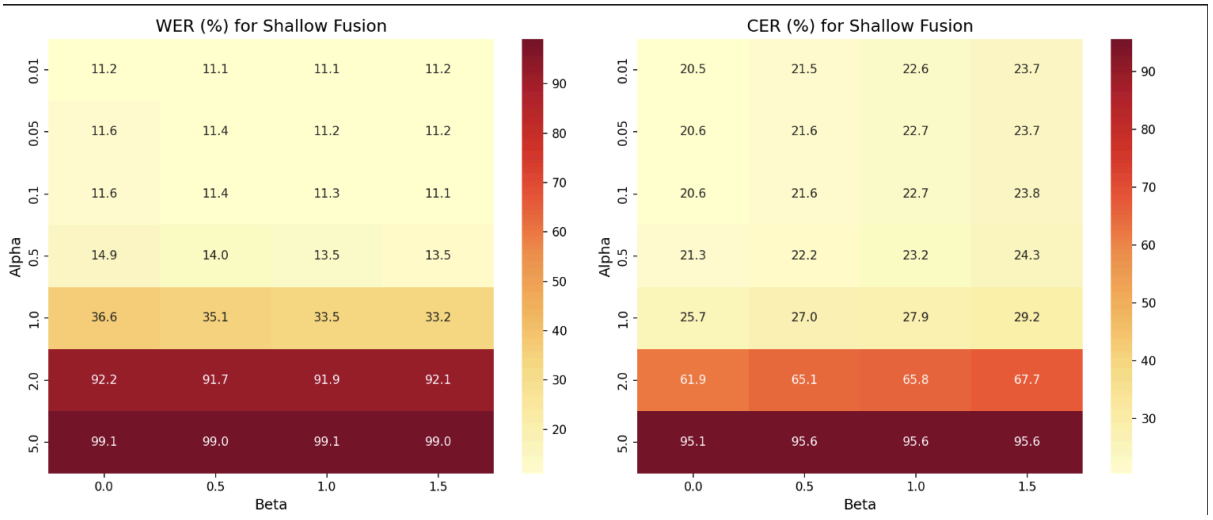

График 3. Тепловая карта WER для shallow fusion

Лучшие параметры:

- alpha = 0.1, beta = 1.5 → WER = 11.10% (CER = 23.76%)
- alpha = 0.01, beta = 1.0 → WER = 11.12% (CER = 22.59%)

При маленьких alpha (0.01-0.1): LM оказывает слабое влияние, WER близок к greedy (11.22%). При alpha = 0.5-1.0: WER ухудшается до 13-15%, LM начинает доминировать. При alpha ≥ 2.0: Качество резко падает (WER > 35%), LM полностью подавляет акустическую модель.

Интересно, что улучшение WER небольшое, но CER ухудшился в 6 раз.

Task 6. LM rescoring

LM rescoring сначала формирует луч гипотез с помощью beam search (без LM), а затем переоценивает их с учетом LM.

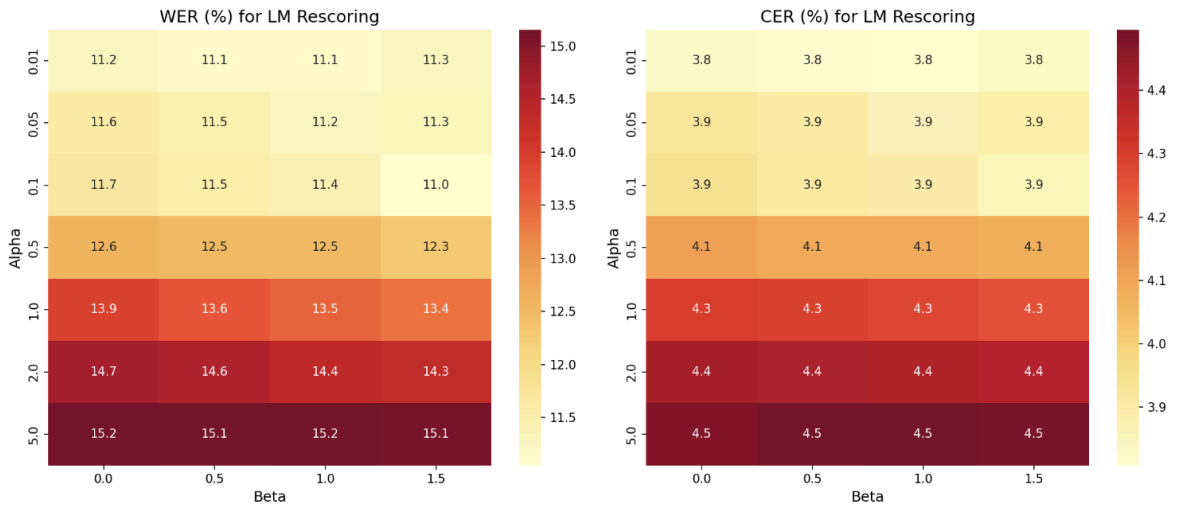

График 4. Тепловая карта WER для LM rescoring

Наилучшие параметры:

- alpha = 0.1, beta = 1.5 → WER = 11.05% (CER = 3.85%)
- alpha = 0.01, beta = 1.0 → WER = 11.12% (CER = 3.81%)

Сравнение shallow fusion vs rescoring:

Параметр	**Shallow Fusion**	**LM Rescoring**
Лучший WER	11.10%	11.05%
Лучший CER	23.76%	3.85%
Стабильность при больших alpha	Сильно деградирует (>35% WER)	Стабилен (до 15% WER)

CER принципиально лучше - Rescoring сохраняет правильное форматирование, в отличие от shallow fusion. WER чуть лучше: 11.05% против 11.10% Стабильность - Rescoring более устойчив к большим значениям alpha, так как LM не влияет на формирование луча

При shallow fusion LM влияет на процесс расширения луча на каждом шаге - если LM на раннем этапе отдает предпочтение ошибочному варианту, правильная гипотеза может быть отброшена. При rescoring LM применяется

только после формирования луча, поэтому правильная акустическая гипотеза сохраняется, даже если LM дает ей низкую оценку.

Примеры:

Ниже даны примеры, где языковая модель изменила предсказание по сравнению с обычным beam search.

REF: ...had a pretty good stock
BEAM: ...had a petty good stock
SF: ...had a petty good stock
RS: ...had a pretty good stock ✓ `corrected`

BEAM и SF ошиблись с "pretty" → "petty", но rescoring вернул правильное слово.

REF: won't do said ram grinning
BEAM: won't do said ram grinnin
SF: won't do said ram grinnin
RS: won't do said ram grennin ✗ `introduced error`

Однако rescoring может и ухудшить результат. Оригинальная ошибка BEAM - "grinnin" вместо "grinning" (пропущена буква 'g'). Shallow fusion сохранил эту ошибку. Но rescoring не только не исправил её, но ошибся по-своему - "grinning" → "grennin".

REF: hopping about like a cat on hot bricks
BEAM: hopping about they gad cat on hut bricks
SF: hopping about they gad cat on hut bricks
RS: hopping about they ad cat on hut bricks ✗ `introduced error`

Ни один метод не смог восстановить исходную фразу. BEAM и SF дали идентичный ошибочный результат. Rescoring немного изменил "gad" → "ad", но не в лучшую сторону.

REF: yes sir of course

BEAM: yes sir of course

SF: yes sir of course ✗ `introduced error`

RS: yes sir of course

Акустическая модель распознала фразу идеально (BEAM верный). Shallow fusion, несмотря на правильные слова, добавил лишние пробелы: "yes sir of course". Это не меняет WER (слова те же), но очень сильно влияет на CER, потому что каждый лишний пробел считается ошибкой.

Это объясняет, почему у нас в результатах CER для shallow fusion вырос с 3.81% до 23.76% при практически неизменном WER (11.10% vs 11.22%).

Паттерны ошибок

– В основном LM не исправляет акустические ошибки, особенно с именами и редкими словами;

– LM добавляет лишние пробелы.

Task 7. Сравнение методов на Earnings22

Method	**LibriSpeech WER**	**LibriSpeech CER**	**Earnings22 WER**	**Earnings22 CER**
GREEDY	11.22%	3.81%	54.97%	25.58%
BEAM	11.22%	3.81%	54.97%	25.58%
SHALLOW	11.10%	23.76%	56.42%	39.60%
RESCORE	11.05%	3.85%	55.45%	25.64%

Анализ сводной таблички:

1. Разрыв между доменами: WER на Earnings22 в 5 раз выше, чем на LibriSpeech (55% vs 11%). Это значит, что доменная адаптация очень важна.
2. Почему LibriSpeech LM не помогает на финансовой речи?
    - Языковая модель обучалась на художке (аудиокниги)
    - Финансовая терминология ("earnings", "revenue", "quarterly results") отсутствует в обучающем корпусе
    - Стиль речи (формальные earnings calls vs разговорная речь) различается

3. Shallow fusion ухудшил качество на Earnings22 (56.42% WER vs 54.97% greedy). Это произошло потому, что LibriSpeech LM активно "исправляла" финансовые термины на общеупотребительные слова, не подходящие для контекста.
4. Rescoring показал WER чуть получше (55.45% vs 56.42% у shallow), но все еще хуже greedy. Это подтверждает, что на OOD данных лучше полагаться на акустическую модель.

Task 7b. Влияние температуры на out-of-domain данных

Температура	WER	CER
0.5	55.09%	37.15%
1.0	56.42%	39.60%
1.5	57.65%	42.36%
2.0	59.43%	45.39%

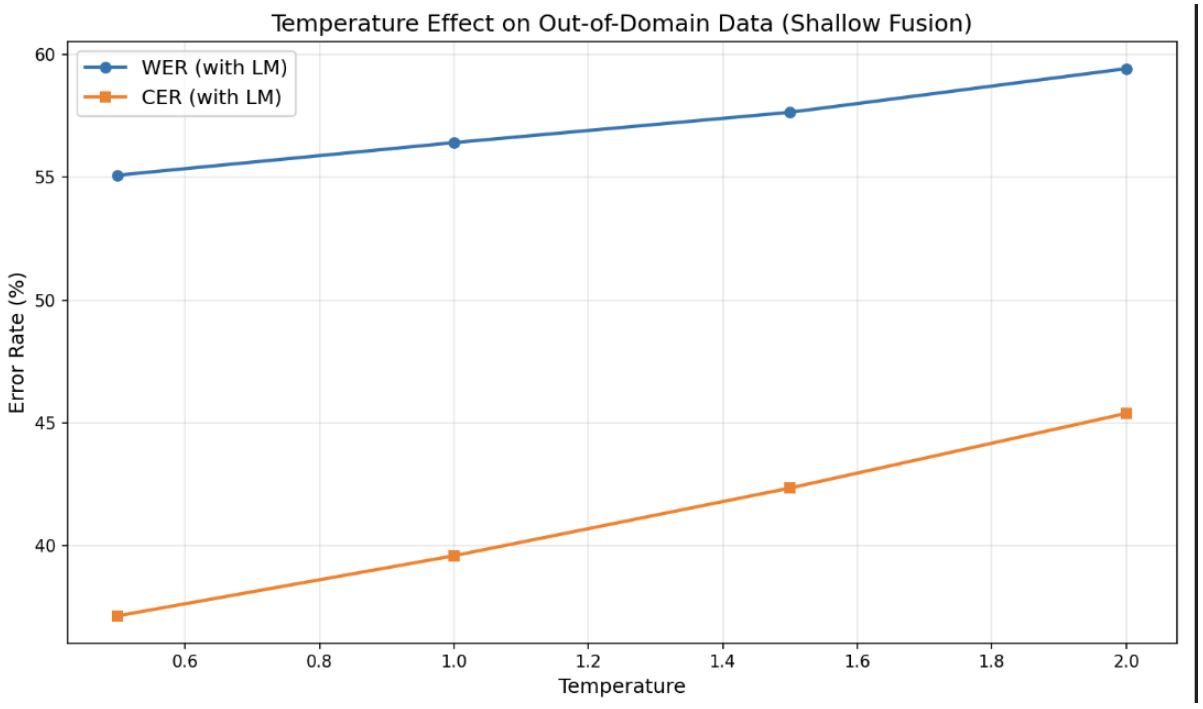

График 6. Влияние температуры на shallow fusion (Earnings22)

Низкая температура (T=0.5) дает лучшее качество (55.09% WER). Повышение температуры ухудшает качество — модель становится менее уверенной, LM начинает доминировать. В отличие от in-domain данных, здесь температура влияет на результат, потому что акустическая модель чувствует себя неуверенно на незнакомом домене.

Почему низкая температура помогает?

При T=0.5 распределение вероятностей становится более "острым", модель "уверена" даже в ошибочных предсказаниях, но это уменьшает влияние LM, которая на данном домене только мешает. Это подтверждает, что на OOD данных лучше полагаться на акустическую модель, даже если она ошибается.

Выводы по методам:

1. Greedy — оптимальный выбор для in-domain данных;
2. Beam search — не дает преимуществ без LM на in-domain, только замедляет;
3. Shallow fusion — дает минимальное улучшение WER (0.12%), но критически портит CER из-за проблем с форматированием;
4. LM rescoring — лучший метод среди LM-интеграций: улучшает WER (0.17%), сохраняет CER, более стабилен.

Ответы на вопросы из домашки

Q: Как температура влияет на greedy decoding?
A: На in-domain данных температура не влияет на greedy decoding, так как argmax не чувствителен к температуре при уверенной модели. На out-of-domain данных низкая температура улучшает качество, уменьшая влияние LM.

Q: Какие параметры alpha/beta оптимальны для shallow fusion и rescoring?
A: Оптимальные параметры: alpha=0.1, beta=1.5. При alpha > 1.0 качество резко падает.

Q: Как rescoring сравнивается с shallow fusion?
A: Rescoring стабильнее, не портит CER, дает лучшее качество. Shallow fusion может быть более мощным, но требует тщательной настройки и несет риск ухудшения.

Q: Какие ошибки исправляет LM?
A: LM редко исправляет ошибки. В моей выборке из 100 примеров был только один успешный случай (petty → pretty).

Q: Какие ошибки LM делает хуже?
A: LM добавляет лишние пробелы (что сильно портит CER), может заменять правильные слова на ошибочные.

Q: Почему LibriSpeech LM не помогает на Earnings22?
A: LM обучена на аудиокнигах и не знает финансовой терминологии. Стиль речи различается, поэтому LM исправляет финансовые термины на общеупотребительные слова, что ухудшает качество.